Intelligent UI 第二阶段增量报告

v2.13 · 2026-10-30 · 封存集对比与桌面动作修复

当前处于开发与验收收尾，尚未发布。按用户安排，CI 留到三个阶段功能开发后统一处理，不以 CI 阻塞阶段间推进。本报告记录本次增量，保留此前各版本证据。

1 修复真实桌面动作流程

实测发现：模型生成界面后，聊天自动命名会追加 session_info 标题记录。原来的动作来源摘要把标题变化当成分支变化，导致读入参数无法采用，保存确认或拒绝返回冲突。

修复只在动作身份中折叠末尾无分叉的标题记录。参数仍从实际历史叶子读取；真正的分支、消息、参数或界面变化继续阻止旧动作。过期确认会结束等待，修改参数后仍可拒绝，同一个确认只消费一次。

Windows 桌面复验

使用真实 Flash 模型、Electron、Next HTTP 和默认 Plan2；独立测试目录与配置。初始 4 人、餐费 40 元/人、门票 30 元/人、车费 120 元。读入后为 7 人、餐费 55 元/人，总额 715 元。

操作	结果
读取参数后刷新，再点击采用	读取不自动改值；刷新保留待采用结果；明确采用后生效
拒绝保存、取消保存	均不创建文件，当前参数不变
等待保存确认时把人数改成 8	旧确认被拒并结束等待，保留 8 人，不写文件
恢复 7 人并重新确认保存	确认前无文件；确认后 JSON 与当前参数一致
再保存到已存在的文件	拒绝保存，已有文件字节不变
刷新并追问当前人数与总额	恢复 7 人、55 元；回答 7 人、715 元，没有再次生成 UI

最后一次复验已等到服务端空闲。截图已查看；客户端状态提示可能稍晚于服务端更新，本轮没有把截图作为客户端终态断言。测试凭据已清理，专用进程已退出。

相关本地检查

动作与标题回归 24/24；数值报告工具 10/10；均无跳过。类型检查、相关 ESLint 通过。修复前保留了 17 项测试中 2 项失败及桌面冲突证据。没有运行 CI 或本地发布构建。

2 冻结封存集的同条件对比

本轮共 26 个任务族：10 个交互、6 个文字、5 个澄清、5 个能力边界；两模型、两协议、各重复三次，共 312 次任务。含文字追问后，每个模型/协议组合有 30 个交互任务、21 个文字回合、15 个澄清回合和 15 个边界回合。

原 20 个封存任务未改动，补充 6 个边界任务。任务、标签、数值期望和判分规则均在模型调用前冻结；旧协议与 Plan2 按任务交替执行。原协议使用冻结的第一阶段工具与当前宿主接纳路径，不代表历史发行版的端到端表现。

观察值	Flash 旧协议	Flash Plan2	Pro 旧协议	Pro Plan2
完成且首次结构有效	24/30	28/30	27/30	29/30
预算内完成且最终结构有效	28/30	29/30	30/30	29/30
首次数值轨迹匹配	18/30	28/30	23/30	29/30
最终数值轨迹匹配	24/30	29/30	27/30	29/30
应交互却没有 UI 尝试	0/30	1/30	0/30	0/30
应交互任务中多次尝试	12/30	5/30	9/30	4/30
UI 耗时 P95（含失败）	120.00 秒	18.65 秒	35.42 秒	28.33 秒

模型条件：low、最多 6000 输出 token、每回合最多 4 次请求、供应商重试 0、任务期限 120 秒。实际 UI 接纳沿用 3 次尝试、1 次纠错、60 秒活动窗口。两模型的声明依赖与快照哈希一致；快照覆盖 23 个声明文件，不等于整个依赖闭包。

运行结果：Flash phase1：completed 78；Flash plan-2：completed 77、provider-error 1；Pro phase1：completed 76、timeout 2；Pro plan-2：completed 76、provider-error 1、timeout 1。以上失败全部保留，没有补跑替换。Flash 达到六项技术开发目标；Pro 达到六项技术开发目标。失败 UI 任务按至少 120 秒计入最近秩 P95，完成文字降级也不算 UI 成功。

Pro 新版最终结构有效比旧协议少一次，数值匹配则多两次；不能宣称每个指标都改善。Flash 五次、Pro 四次多调用也不全是纠错，包含生成有效版本后的再次更新。

数值检查独立改变输入并核对预先写定的输出轨迹；它能发现“格式合法但结果写死”等问题，不能证明所有边界输入、文案或业务语义正确。重复三次用于观察稳定性，不能把 26 个任务族当成 78 个独立任务族。

3 触发判断、限制与后续

回答形式选择

观察值	Flash 旧协议	Flash Plan2	Pro 旧协议	Pro Plan2
应直接回答回合中尝试 UI	3/21	0/21	0/21	0/21
需先澄清回合中尝试 UI	11/15	0/15	8/15	0/15
能力范围外回合中尝试 UI	7/15	0/15	1/15	0/15

策略继续由同一轮模型结合上下文选择直接回答、先澄清或生成 UI；程序控制能力范围、版本与预算。没有关键词路由，也没有增加一个分类模型请求。新版本次没有这些误调用，但 Pro 的一次澄清超时不能算正确回答；此前开发集仍有能力误触发。“不调用 UI”不证明问对了问题。

本轮非完成记录：flash/plan-2/h10/第 1 次：provider-error；pro/phase1/h23/第 1 次：timeout；pro/phase1/h23/第 3 次：timeout；pro/plan-2/h05/第 3 次：provider-error；pro/plan-2/h23/第 1 次：timeout。这些是实际观察到的失败，无法仅凭本轮归因于模型、供应商或新协议。

澄清/能力边界中的 UI 尝试：flash/phase1：h17 2/3、h18 3/3、h19 2/3、h20 3/3、h21 2/3、h22 1/3、h23 3/3、h25 2/3；pro/phase1：h17 2/3、h18 3/3、h20 1/3、h21 1/3、h22 1/3、h23 1/3。逐任务用户输入、最终回答、诊断和各模型比较均保存在 JSON 证据中，不能用总成功率掩盖这些失败。

当前结论与剩余工作

- 这批任务提供有限的跨领域证据，仍共享已有算术与组件能力。封存任务现已暴露；若据其输出调优，应转为开发集，并另补未见任务验证。
- 数值轨迹匹配不覆盖零除提示、静态标题与动态结果的一致性、全部输入边界。桌面示例的模型文字还存在把读取与保存的确认要求混说的问题，需要语义修正。
- 桌面结果限于一个 Windows、Flash、JSON 流程；不是全部模型、权限模式、文件格式和跨平台矩阵。独立人工语义评判与完整产品验收仍未完成。
- 继续完成这些剩余功能与体验问题，并按三阶段计划推进。当前六项技术目标不能代替产品验收，CI 后置也不等于通过。

可复核材料

封存计划：intelligent-ui-phase2-heldout-plan-2026-10-30.json；逐任务结果：intelligent-ui-phase2-heldout-2026-10-30.json；桌面流程：intelligent-ui-phase2-action-workflow-2026-10-30.json，均在 docs/verification。原始模型记录在 .verification/intelligent-ui-heldout-2.4，桌面记录在 .verification/desktop-phase2-actions-v10。

本轮工作位于本会话独立工作树、codex/intelligent-ui 分支，尚未提交或推送。没有新增任意代码执行能力，第一阶段兼容与普通文字路径继续保留。