Intelligent UI 第二阶段实施进展

版本 v2.0 · 2026-10-29 · 实现中，尚未验收或发布。

第二阶段正在落实“自然表达、合适的回答形式、稳定生成、保存后继续追问”。当前已接入触发策略和已保存 UI 上下文，完成有界计划编译器及评估工具的原型，并开始接入运行预算与候选提交。完整阶段仍包含 2A、2B、2C、2D，不能以原型测试代替全部交付。

工作在本任务独立工作树、分支 codex/intelligent-ui 中进行。已 rebase 到 upstream/main 4ba01185，基础版本为 beta.59；当前分支 HEAD 62c7401c，本报告记录其后的未提交修改。原第一阶段 PR #238 尚未因本轮工作更新。

1 触发判断怎样实现

当前方案是同一轮模型判断加程序约束。每次请求使用版本化策略 intent-1；正常聊天层无需判断“预算”“计划”等词，也没有额外的分类模型请求。开启 Beta 功能时才向模型提供对应能力。

判断依据	预期行为
一次性计算、解释、写作、静态比较	用文字或普通表格回答
用户需要反复改条件并观察有意义的联动	能力范围内创建或更新 UI
缺少会改变结论的价格、规则、数据来源	先澄清关键事实，避免编造
只缺颜色、布局等低风险展示细节	系统选择合理默认值
已有 UI，用户问结果原因	结合已保存参数解释，不重新生成
已有任务需要增加比较项或修改结构	使用稳定任务 ID 更新
明确要求纯文字，或当前能力无法表达	尊重形式要求；说明能力边界并给可用替代

“480 元六个人分”直接回答每人 80 元；“人数和费用我想自己改着看”适合 UI。前一轮回答金额、后一轮要求可调整，是文字转 UI；已有 UI 后问“为什么”，则转回文字解释。相同话题可以采用不同回答形式。

模型同时读取当前分支的已确认参数、任务 ID、界面版本、参数版本和摘要。上下文保留完整 JSON，超过长度时明确标记省略，优先保留近期任务；未保存参数不会伪装成已保存值。这些内容是任务数据，不能作为工具授权或覆盖系统规则。

程序保证功能开关、协议和成本限制，不能保证语义选择正确。是否选对形式、计算是否符合任务、结构是否有效、是否真正保存分别评估。若同轮决策在完整评估中仍不稳定，再比较额外分类器的收益和延迟，当前不预先增加这笔成本。

2 本轮成果与接入边界

工作项	当前成果	仍需完成
2A 策略与评估	版本化决策策略已接入；60 个合成任务按开发与封存集合划分；记录未调用 UI 的回答及逐轮选择	完整基线、独立语义验收、锁定目标、封存集复测
2B 计划编译	平铺输入与命名计算原型；检查引用、环、类型、运算参数数量及展开成本；编译回可信 Surface v1	接入真实工具和持久提交后再决定是否替换原协议
2B 运行预算	已接入 SDK 参数校验前接纳、普通及嵌套调用、截断调用和 PromptRun 绑定；真实 wrapper 回归通过	与新计划、候选提交和 UI 错误状态继续集成
2B 候选提交	独立 journal 原型、准确磁盘回执、版本比较、幂等和故障注入测试；支持观察同轮多个 SDK 工具结果	正式运行时连接、统一锁域、历史读取与客户端恢复
2C 丰富交互	设计保留分组布局、方案卡片、筛选表格、可取消的已校验预览	尚未实现
2D 动作和交付	保留受控动作、权限、幂等及端到端交付要求	尚未实现或验收

预算原型为每个 PromptRun 最多 3 次 UI 尝试、最多 1 次模型纠错、首次 UI 尝试后 60 秒活动窗口。它不是每个控件的额度，也不代表整个对话最多等待 60 秒。网络重试和模型回退不重置逻辑身份。参数校验前失败也要计数，不能只在工具 execute 中拦截。

计划编译器没有任意 JavaScript、HTML 或字符串公式执行能力。默认数字输入框；只有明确、合理的边界和连续调整需求才使用滑块。它简化模型表达方式，但不会自动推断业务公式，也不会保证生成质量提高。

候选 journal 原型尚不能视为生产事务：SDK 会自行写入工具结果，适配必须观察准确的磁盘回执，不能重复追加；旧参数写入、分支导航、候选发布还要统一并发边界。新版本发布与未保存草稿恢复仍属于 2B 的交付范围。

3 真实模型试跑结果

本次试跑使用 6 个开发任务族、2 个模型、3 种协议或策略、每组 1 次，共 36 个完整任务记录。任务包括 3 个应交互、1 个直接回答、1 个先澄清和 1 个能力不支持的场景。模型为 DeepSeek Flash 和 DeepSeek V4 Pro；未读取封存集模型输出。

固定条件：low reasoning，最多 4096 输出 token，每轮最多 4 次模型请求、8 次工具尝试，供应商重试为 0，适配器超时 90 秒。该实验预算与生产候选预算不同；只比较同一实验环境，不据此宣称生产上限已验证。

模型	策略	UI 首次结构有效	UI 最终结构有效	3 个 UI 任务的调用总数
Flash	第一阶段	2/3	3/3	5
Flash	intent-1	3/3	3/3	3
Flash	plan-1	1/3	3/3	5
V4 Pro	第一阶段	2/3	3/3	4
V4 Pro	intent-1	2/3	3/3	4
V4 Pro	plan-1	1/3	3/3	5

36 次试跑中，34 次完成适配器对话流程，2 次记录为 timeout。timeout 分类还包含输出截断或请求次数耗尽，不能都理解为等待超过 90 秒。完成对话不等于交互产品可用。

直接回答和先澄清的样例，在六个模型/策略组合中均未调用 UI。能力不支持样例仍出现不合适的尝试：Flash 第一阶段调用 2 次，Flash intent-1 调用 1 次且输出截断。其余组合没有 UI 调用，但其中 V4 Pro 第一阶段未完成对话，不能计为正确解释能力边界。

旧协议曾因生成引用或表达式不符合规范而多次重试；平铺计划也出现 PLAN_ARITY 与 PLAN_SHAPE。当前小样本没有证明新协议提高首次成功率。普通语言策略在 Flash 的三个 UI 样例上表现较好，样本不足以证明跨领域或跨模型改善。

结构检查还不能替代语义验收。抽查中，某个旧协议输出声称金额保留两位小数，却使用整数 round 运算；默认人数下结果仍恰好正确。这说明需要同时核对变更输入后的计算和对结果的文字解释。

试跑只运行隔离模型与编译器，不接浏览器、保存、刷新或真实任务权限。没有把 committed 标为 true，也没有伪造独立人工评审。此处的“结构有效”不能称为首次可用率、最终可用率或生产验收结果。明细和冻结实验摘要见试跑证据 (verification/intelligent-ui-phase2-pilot-2026-10-29.json)。

4 验证与 Review

本机为 Windows，相关检查使用 Node.js 22.19.0。重新按锁文件安装依赖成功；没有执行 next build 或构建发布包。

最终相关回归覆盖 17 个文件，131/131 通过，0 失败、0 跳过。范围为原 UI 核心、参数状态、Beta 切换、触发策略、上下文、评估、模型适配器、计划编译、运行预算、journal 和 SDK 完整性。它是相关回归集合，不是仓库全量测试。

真实 wrapper 场景覆盖模型回退保持预算、旧工具上下文不能借用新运行、权限拒绝和重复调用终止；磁盘回执场景覆盖同轮多个结果、观察不重复追加，以及同一任务两个候选不能同时发布同一版本。新增的模型失败处理保留已知 UI 调用证据，避免把供应商报错误记为未触发。

执行命令：在 Node.js 22.19.0 环境下执行 npm run typecheck、npm run lint、npm run verify:hygiene；相关测试文件由 rg --files lib 筛选名称包含 intelligent-ui、answer-output、beta-features 或 pi-source-profile 且以 .test.mjs 结尾的文件，再以 node --test 执行。原始文件清单与输出保留在本地 .verification/intelligent-ui-phase2-test-files.txt 和 .verification/intelligent-ui-phase2-tests.log。

独立 Review 已复核两项评估问题：工具调用按所属轮次计分，前轮误触发不能抵消后轮漏触发；供应商错误或中断保留失败调用证据。相关复核 45/45 通过。choiceCorrect 被否定时不记可用，评审分歧及旧多轮记录缺少逐轮标签时保持 pending。

最终代码修改后的 Web 与 Desktop 类型检查通过；全仓 lint 为 0 错误、4 条现有告警，后续修改文件的局部 lint 通过。仓库卫生检查与 diff 格式检查通过。当前没有完整测试集通过、真实浏览器验收、桌面实机验收、跨平台验证或 GitHub CI 通过的结论。

5 下一步交付门槛

先完成预算和候选提交的生产连接，核实取消、迟到结果、多工具结果、并发改参、分支与旧草稿恢复；再进行包含保存、刷新、追问的完整对话评估。新输入协议是否启用，以完整对比证据决定，不能因已投入开发就直接替换。

之后交付 2C 的组件组合与预览，以及 2D 的已登记动作和权限闭环。每个子阶段补充实际成果、失败记录和 PDF。全部 2A 至 2D 达到对应门槛前，第二阶段保持实现中。

参考：设计基线见 第二阶段设计 (intelligent-ui-phase2-design.md)，实验执行说明见 评估工具说明 (../scripts/evaluate-intelligent-ui.md)，历史成果见 阶段报告 (intelligent-ui-phases.md)。