PIORA / INTELLIGENT UI

第三阶段成果：数值比较与模型配置对照

2026-11-02 | 专用工作树 intelligent-ui/Piora | 分支 codex/intelligent-ui

1. 本批交付

组件补齐四种数值比较，并完成固定模型配置下的自然表达复测。 原始生成结果在 Windows 开发桌面完成操作、保存和追问；仍有模型语义问题，第三阶段尚未完成。

改动	行为与边界
数值比较	lt/lte/gt/gte：两个数值操作数，返回布尔值；支持命名计算与内联表达式，正确区分严格与含等号边界
兼容与限制	使用比较记为编译器 2.7.0，转换成现有 Surface2 表达式；原有 2.5/2.6 计划身份及 Plan1 契约不变，计算数量、深度、展开预算不增加
模型配置核验	探针支持显式开启/关闭推理，出网前检查 deepseek-flash 和 thinking；不启用 Pro、fallback 或额外重试，不修改用户设置
原始组件重放	SHA-256 绑定原始报告，实际数字框操作、独立结果、自动保存、刷新及真实追问；读取 API 只核对结果
稳定测试窗口	自动化只编译一次桌面开发夹具，避免监听器中途重启；普通交互式开发仍热重载，不构建发布包

比较不推断规则、不转换数字字符串，也不放宽 if 的分支类型。三次接纳尝试、一次纠错和六十秒窗口保持原样。能力证明新增实际依赖的组件编译器、表达式与决策源文件，避免代码变化后沿用旧证明。

2. 开发检查与失败留存

能力检查 **490/490**，覆盖 55 个相关文件，14 项能力由宿主读取确认。新增比较与预览检查 17/17，覆盖负数、小数、正负零、相等、$\pm 10^{12}$、SDK 传输、流式边界、序列化恢复、惰性求值及资源上限。既有组件与纠错回归 54/54；这些与 490 项有重叠，不能相加。TypeScript、本批源文件 lint 通过。

首轮比较测试 6/8：一个字符串输入夹具缺少必填 options，一个深度夹具先触发 JSON 层限制；修正为合法输入和命名深度链，保留原日志并补充展开预算检查。桌面生命周期/评估工具检查 23/23，随后隔离模式断言修改后的生命周期检查 19/19，范围重叠。

首次原生重放被桌面 TypeScript 监听的多次重启打断，记录在 desktop-e2e-9samm0，不能计为任务通过。修正自动化编译模式后重新执行完整九份组件；两次运行的进程清理均无错误。不是完整 CI 或其他平台验收。

3. 同一 Flash 模型的配置对照

三个开发任务为满减、包邮、两侧温度阈值，每例三次。两组产品代码完全相同，源摘要差异仅为增加显式推理参数的探针。不是随机对照实验，不能外推为整体成功率。

配置与任务集	请求数	预期 UI 形式发布	首试发布	文字/澄清无误触发
关闭推理，三类阈值	9	2 / 9	1 / 9	不适用
开启推理，三类阈值	9	9 / 9	7 / 9	不适用
开启推理，原八类任务各三次	24	18 / 18	12 / 18	6 / 6

关闭推理时另有两次发布成小程序，计入总发布 4 次，但不算预期组件形式成功；包邮三次均因生成结构或分支类型错误失败。温度三次均选择小程序，其中一次生成失败。没有删除失败、补跑替代样本或调整预期形式。

模型配置名为 **DeepSeek V4.1 Flash**，实际请求及返回 ID 为 deepseek-flash。开启组 SDK 选择 medium，供应商适配后的 HTTP 请求为 thinking=enabled、reasoning_effort=high；关闭组为 thinking=disabled。不能从供应商返回的泛化 ID 独立证明内部版本。三组请求分别冻结，所有计划样本均结束，模型/流错误为零；生成失败仍保留在分母。

4. 原始组件在开发桌面的结果

开启推理组九份原始组件不作任何修改，完成 **33 个输入检查、9 次刷新恢复和9次真实追问。**每次追问的实际请求含最后保存参数，没有重新生成 UI；九次追问均为指定 Flash/开启推理，HTTP 200。另九次后台标题请求独立记录，不算追问。

任务	独立预期	实际操作范围
满减（三份）	5 杯付 90，6 杯付 88，8 杯付 124；均价 18、约 14.67、15.5	九个数值检查，最终保存8杯，刷新后追问124元/15.5元
包邮（三份）	199 元加12元运费，共211；200/201元运费为0	九个边界检查，最终保存201元，刷新后追问运费0/合计201
温度（三份）	17.5冷，18/20/26刚好，26.5热	十五个边界检查，最终保存26.5度，刷新后追问“热”

完整检查点文字及追问经开发代理复核，与独立结果一致；不是两人独立人工语义验收。已查看三类各一张浅色窗口截图，可见数字框、卡片、表格与动态说明清晰；未将屏幕外区域、其余截图、暗色及窄窗计为外观通过。

整体原生任务报告仍为 failed。 discount-2 添加了用户未提供的最大100杯，shipping-2 添加了最大1000000元。两份记为 semantic-failed，另七份机械流程完成。保留生成上限，不改程序使测试通过；数值检查和追问完成不代表任务全部正确。

5. 剩余工作与复现

仍需解决关闭推理时的结构失败和形式选择、未经提供的输入边界、复杂小程序的过程说明与任务泛化。原八类24次仅完成本批生成验证，不能用九份阈值重放替代其中18份 UI 的完整操作验收。原生最小化/关闭恢复组合、32例开发集及48例整体分布仍有未完成项；完整 CI、封存集及人工综合验收按约定留到开发完成后。

代码说明：docs/intelligent-ui-numeric-comparisons.md；重放协议：docs/intelligent-ui-natural-task-replay.md。运行入口为 verify-mini-app-capabilities.mjs、evaluate-mini-apps.mjs --run --thinking enabled，以及 verify-recorded-component-tasks.mjs --bindings 对应绑定文件。后者依赖原始生成报告，不能离开产物当固定 CI 使用。

证据目录：能力 Rq9wDA；阈值关闭 R82OkE、开启 lRz2vq；八类任务 DSNO1F；原生复测 PQPiGO。完整相对路径、摘要、配置、失败和范围见同名 JSON，不将“发布”写成“语义通过”。