PIORA / INTELLIGENT UI

# 按需试算与第三阶段提交报告

2026-11-03 · 开发中版本 · Windows 开发桌面 · upstream Draft PR #238

本批将小程序追问中的局部预演改为按需工具。当前状态问题直接读取已确认快照；需要了解某个按钮后果时，模型调用 piora_inspect_mini_app，宿主只读试算指定操作。能力检查通过，但真实回答仍有额外错误推断，第三阶段尚未完成。

## 本次实现

- 默认上下文保留当前参数、状态、摘要、列表与场景信息，并提供有界按钮目录；移除每轮自动执行备选操作和自动注入全部预演结果。
- 工具只接受已有应用 ID 与 1 至 12 个不同的局部按钮 ID，不接受代码、任意事件、文件动作或模型提供的检查点。每个按钮从同一快照独立试算，不串联成操作路线，也不点击用户界面。
- 试算前后检查发起请求、会话分支、发布来源、状态版本和检查点；缓存查询也复核来源。每轮最多 12 次查询，缓存最多 16 项，结果延用 4500 字符预算和字段完整性标记。取消或来源过期即拒绝。
- Beta 关闭时不注册工具，工具沿用已有会话权限。只读试算不保存新版本，不替代文件动作授权、业务规则核验或目标判断。
- 公共回答策略更新为 answer-form-5，小程序策略为 mini-app-intent-22。根据用户实际问题区分当前状态、单次后果、过去过程和未来路线；不新增关键词路由或独立分类模型调用。

## 开发验证

| 检查 | 结果与范围 |
| --- | --- |
| 能力验证 | 最终 cqASrU：57 个测试文件、520/520 通过，14 项能力证明；169 个源码/测试摘要与当前文件匹配。此前 7WGWfH 同为 520/520，范围重叠不累计。 |
| 定向检查 | Web TypeScript、修改模块 ESLint、公共策略测试 4/4 通过。提交核对不重复执行已通过的完整能力或模型场景。 |
| 首次失败 | 未使用隔离 agent 目录的定向运行 24 通过、7 失败，原因是能力证据过期被正确拒绝；首次类型检查发现错误返回缺少 details，已修正。最终能力入口在隔离目录重新生成并核验凭据。 |
| 来源核对 | 最终桌面运行前记录的 119 个文件摘要，以及能力验证的 169 个摘要均保持一致；重放记录核对原生成文件未被修改。 |

测试覆盖输入拒绝、仅执行选中按钮、无关死循环按钮不运行、字段变化与省略、缓存过期、分支变化、取消、状态保持和真实 SDK 工具接入。确定性测试不能证明自然语言回答或任意生成程序正确。

# 真实桌面与模型追问

使用配置名 DeepSeek V4.1 Flash，请求为 deepseek/deepseek-flash，追问实际请求的 thinking 为 enabled；未使用 Pro 或模型回退。后台标题请求的 thinking 为 disabled，单独记录，不计入追问。服务返回别名不能独立证明内部模型修订。

被验证的操作经桌面 UI 执行；接口和存储读取用于准备、独立预期核对及保存确认。旧任务重放与新生成后的组件验证分开统计。

| 运行 | 功能结果 | 回答审阅 |
| --- | --- | --- |
| F8c9eK，初版策略 | 5 份旧小程序，58 项操作、12 次刷新；5 次追问、6 次模型请求。 | 两份量杯仍出现错误的普遍性断言，保留为失败，不计作语义修复。 |
| DcqEBV，最终策略 | 相同 5 份旧程序，58 项操作、12 次刷新；4 个当前状态问题未调用试算，排序下一步调用一次。 | 请求的数值与下一步事实正确；排序额外称“第 11 步”，误用宿主 tick；第三份量杯额外建议重置。 |
| lp93uA，明确询问后果 | 3 份旧程序，38 项操作、7 次刷新；3 次追问各调用一次试算。 | 两份倒空 3 升杯的结果均为 0/4，棋盘结果为 O 落左上后轮到 X；其中一份量杯又附加错误限制。 |
| 5yxALr，新组件 | 4 份本批新生成组件，15 次输入修改、4 次刷新、4 次真实追问。 | 出行 2/4/6 人及满减 5/6/8 杯符合独立预期；一份另测 0 杯。4 份回答未发现事实错误。 |

最终旧程序重放与明确后果验证均检查试算来源、实际工具调用、字段前后值，以及追问后检查点和 stateRevision 不变。原始文件摘要保持一致，页面和清理错误为空。这些结果验证功能链路，不能把脚本中的 completed 当成完整语义通过。

# 明确保留的问题

- 排序的运行时 tick=11 不是任务“比较了 11 次”或“第 11 步”；此前重置后，业务状态为比较 2 次、交换 2 次。模型仍把内部计时元数据当作业务进度。
- 一份量杯后果回答在正确的 0/4 结果后声称，只有倒空 5 升杯或倒入 3 升杯才会改变 4 升。反例是装满 5 升杯也会改变水量，而当前 3 升杯已满，倒入它不会改变水量。请求的结果正确，整份回答仍失败。
- 第三份旧量杯包含 6 条已保存历史日志，回答中的最后一步有记录支持。此前把这部分称为无依据历史的判断已更正；未经请求复述过程或建议重置属于范围问题，不能混为捏造历史。

以上为开发审阅，未代替用户安排的双人人工语义验收。

## 新生成批次：20/24 有完成记录

运行命令为 node scripts/evaluate-mini-apps.mjs --run --repetitions 3 --concurrency 1 --thinking enabled，批次为 0UtSD0。计划 8 个任务各 3 次，共 24 次；进程因 ENOSPC 退出，退出码 1，原汇总 result.json 被截断为 0 字节。未覆盖或丢失的记录不能补记成功。

依据顺序日志和各样本独立 result.json 可复核 20 次完成：6 次直接回答/澄清没有调用 UI，14 次 UI 请求发布成功，其中 13 次首试成功。三角形第一次因不支持的颜色字面值被拒，第二次修正后发布。剩余 4 个计划槽位没有完成证据，完整批次仍为未完成；不能报告 24/24 或 18/18 成功。

这 20 份记录的发布结果不等于任务正确率。只有其中 4 份新组件完成了本批桌面输入、保存、刷新和追问；新排序与新量杯的重放 xD5UTR 在启动阶段就因磁盘不足失败，完成用例为 0，清理同样出现 ENOSPC，锁保留。未继续发起或声称通过其他新小程序桌面用例。

## 空间故障与证据保留

核对时 C 盘可用空间为 0。已确认本批生成和桌面进程终止；迁出四个已结束桌面运行的 Next 构建缓存到 D 盘独立缓存目录，保留测试记录、profile、截图及原始生成结果，释放约 1 GB。未删除其他工作树内容，未覆盖损坏的原始汇总；脱敏报告单独保存从日志核对的 20 个结果及缺失槽位。

本次提交没有为补满统计重跑 24 次模型生成，也没有将迁出缓存当作失败用例复测。后续恢复测试前须核对剩余磁盘空间和失败运行遗留锁。

## 交付与下一步

本次按要求先提交开发中版本，经 codex/intelligent-ui 更新 upstream Draft PR #238。提交前 fetch 确认 upstream/main 为 9540f859，功能分支基线为 d2e67c9f，均未前进；推送前再次检查。PR 正文以当前 head 的提交与 CI 状态为准。

上一 head 的 CI #928 已完成且 failure，涉及 release-tree hygiene 和测试分片；未声明修复。完整 CI 修复、封存集及双人人工验收仍按用户安排留到三个阶段开发完成后。没有执行 next build、本地发布打包或其他平台验收。

后续优先处理内部时钟与业务进度的语义区分，以及正确试算后附加错误结论的问题；恢复未完成生成与新程序桌面验证。继续完成 3B 完整任务、3C 恢复/修订/动作/互转组合和 3D 复杂交互，再进入 3E 综合验收。

证据索引与摘要见同目录 JSON；历史失败和后续复测分别保留，不将本批提交视为第三阶段完成或发布。