PIORA / INTELLIGENT UI

第三阶段：原始生成任务桌面复测

2026-11-02 · 对应实施方案 v3.8 · 本批成果报告，第三阶段尚未完成。

1. 本批结论与范围

这轮把真实模型先前生成的界面放回隔离的 Windows 开发桌面，通过界面改参数、推进、刷新和追问，核对用户实际得到的结果。没有替换原始程序或修正其答案来获得通过。

六份计算组件完成参数变化、保存、刷新和真实追问；修复冷启动投影超时后，两份排序程序完成六步推进、中途及终局刷新、重置、宿主步进和播放。另一份排序程序声明“最多交换 3 次”，第 5 步需要第 4 次交换，因此仍正确停止。新发布检查现已能提前发现这个错误。

这些证据来自修复前后不同批次，不能表述为“当前版本九例全部通过”，也不等于完整语义验收。错误说明、无依据的输入上限和图形语义问题仍保留为未解决项。

范围	本批实际执行
原始样本	先前 24 次生成记录中的出行、杯数优惠、排序，各 3 份，共 9 份；不是新一轮生成成功率评估
桌面环境	真实 Electron 与开发服务器；独立 profile、端口和输出目录，复用公共桌面生命周期
实际操作	输入、点击、重置、播放、刷新及聊天发送均经 UI；接口仅准备和读取状态核对
真实追问	配置 DeepSeek V4.1 Flash，固定 deepseek/deepseek-flash；服务返回 deepseek-flash，未独立确认“4.1”版本身份，无 Pro 或模型回退
凭据与原件	凭据仅供进程内转发，临时 profile 使用合成令牌；不复制原始认证文件，源记录哈希核对不变

对方案的反馈

保留 v3.8 的能力清单、独立运行时及逐任务交付顺序。将“运行完成”“计算正确”“文字与图形一致”“保存后能继续解释”分开记录；发布前有界试运行提供纠错依据，不能代替独立预期结果。剩余任务与复杂能力继续按原范围开发。

2. 九份原始任务得到的结果

原始记录	操作与恢复	语义审阅结论
outing-1 / 2 / 3	各测试 2、4、6 人；数值、保存、刷新及真实追问符合预期	outing-2 静态说明把便宜的一方写反；outing-3 擅自设置最多 20 人
discount-1 / 2 / 3	各测试 5、6、8 杯；总价、均价、保存、刷新及真实追问符合预期	discount-2 / 3 未经用户要求设置最多 200 / 50 杯
sorting-1	修复后六步、刷新、重置、宿主播放及追问完成	原始快照和回答误写 4 次交换；实际为 5 次，后续真实回答纠正了该数字
sorting-2	修复后前四步及中途刷新成功，第五步因状态越界停止	swaps 最大值错误地设为 3；初始图形还把未排序的末项标为“已排好”
sorting-3	修复后六步、刷新、重置、宿主播放及真实追问完成	本批检查的数列、计数与追问答案符合独立预期；未作全面教学语义验收

独立预期结果

- 出行：A = 30 × 人数 + 120，B = 45 × 人数 + 60。2 人为 180 / 150，4 人为 240 / 240，6 人为 300 / 330；因此 1 至 3 人 B 更省，4 人持平，5 人起 A 更省。
- 优惠：本任务每杯 18 元，满 100 减 20。5、6、8 杯应分别为 90、88、124 元；对应均价 18、约 14.67、15.50 元。
- 排序：初始 [6, 2, 5, 1]。六次比较后依次为 [2, 6, 5, 1]、[2, 5, 6, 1]、[2, 5, 1, 6]、[2, 5, 1, 6]、[2, 1, 5, 6]、[1, 2, 5, 6]，累计交换 1、2、3、3、4、5 次。

追问验证的边界

实际追问请求必须携带刚确认保存的参数或小程序摘要及 tick，不能用后台自动命名请求代替。六份计算任务及两份排序任务的回答均与上述最终数值相符；排序回答为 6 次比较、5 次交换。原始报告的人工语义审阅标记仍为待完成；本段是源码、独立计算与本次 AI 审阅结论，不冒充两人独立验收。

3. 已实现的共性修复

冷启动恢复沿用启动预算

恢复一个新虚拟机时，第一次 project 原先使用普通操作的 8 ms 预算，冷启动开销可能导致已保存程序停止。现在首次恢复投影可使用既有 200 ms 启动预算，仍保留累计 CPU、内存及外部超时约束；后续投影、事件和步进继续使用普通预算。失败的首次投影也会消耗启动资格，不能反复续期。

恢复不调用 init，不重置数组、计数、tick 或随机数状态。两项真实 QuickJS 测试使用可控时钟验证：复杂首次投影能恢复原状态；后续过慢投影与无限循环仍被终止。修复前失败记录和修复后桌面证据均已保存。

离散程序发布前最多检查 32 步

新生成的离散程序沿实际声明的步进操作试运行，逐步核对状态结构与渲染结果，到终点或 32 步即停止。连续程序仍只做原有的一步检查，纯事件程序不执行不存在的时间推进。最终发布的仍是初始状态，不会把检查进度交给用户。

错误返回步骤、字段路径和可修复标记，模型可据此纠正声明。原始 sorting-2 已复现为：第 5 步，STATE，state/swaps，repairable=true。通用递增计数器测试同样覆盖首步正常、后续越界，避免只针对排序样本修补。

历史状态读取只投影已保存检查点，不运行未来步骤，也不偷偷更改旧程序。本次没有重新生成排序样本，尚不能声称模型收到诊断后已成功修复它。

该检查只覆盖默认输入下的有界轨迹；第 33 步以后、其他输入与事件路径、公式含义、说明和颜色仍需其他验证。没有增加关键词触发、额外分类模型或无限重试。

可观察性与复用工具

桌面表面分别暴露运行、保存状态及动作错误码，诊断可以区分超时与状态越界。新增原始记录重放入口和真实模型内存转发模块；模型请求与后台命名分开记录，保留失败运行和最终清理结果。

4. 检查记录、失败与后续工作

检查	结果与边界
能力验证入口	55/55 通过；真实 QuickJS、浏览器与确定性夹具，刷新匹配源码的能力证据，不证明所有自然任务正确
冷恢复与发布试运行	合并 6/6 通过，包含在上述范围内，不累计为额外覆盖
真实模型转发模块	2/2 通过：固定模型、认证边界、实际上游鉴权及返回模型记录；这里是转发测试夹具
应用类型与修改文件 lint	正确使用仓库 tsc 入口后通过；11 个相关文件 lint 通过
CI、真人与平台	未执行完整 CI、两人语义验收、其他操作系统、原生最小化或发布安装包验证

首次桌面夹具用独立 HTTP 客户端读取接口被 403 拒绝，已改为页面同源读取；模型转发误解 authHeader 配置造成 401，已修复并测试。早期成功试跑的上下文断言可能命中后台命名，已加强为匹配真实追问及最新参数，其结果不作为最终上下文证据。

随后完整重放的三份排序均失败，诊断发现冷投影 TIME_LIMIT；修复后两份完成，另一份显露其 STATE 越界。上述失败和复测分别保留，未删除或算作通过。最终检查也记录了两次命令入口错误：错误的 tsc 包路径、向 Node Worker 继承 --input-type 参数；改用仓库入口与独立脚本后通过，未改产品断言绕过失败。

证据索引

- 原始生成批次：.verification/mini-app-evaluation-di2ENh/result.json。
- 六份组件及修复前排序：.verification/desktop-e2e-fnNLdD/recorded-tasks.json。
- 冷恢复诊断：.verification/desktop-e2e-agltnz/recorded-tasks.json。
- 修复后排序及真实追问：.verification/desktop-e2e-kwj9QK/recorded-tasks.json；越界定位见 desktop-e2e-B3qXeU 同名文件。
- 最新能力结果：.verification/mini-app-capabilities-lknGV4/result.json；原样本发布检查：.verification/phase3-recorded-trial-rejection.json。
- 本报告同名 JSON 保存各次状态、源文件摘要及本次语义结论；早期夹具失败目录也列在其中。原始桌面运行均无清理错误。

后续交付仍按完整第三阶段推进

继续首批其余任务与完整 48 题评估，验证新生成的首试质量及语义一致性；完成三维环境协商、动态列表、拾取与相机、持续模拟及游戏交互、完整恢复矩阵、修订迁移和登记动作。每批报告分别说明运行、正确性、外观及恢复证据，最后再做已约定的 CI 与人工验收。

工作位于专用 worktree C:/Users/shengjiajun/.codex/worktrees/intelligent-ui/Piora，分支 codex/intelligent-ui，基准提交 b41fa2ff。本批及此前第三阶段修改尚未提交或推送。