PIORA / INTELLIGENT UI

第三阶段成果：生成纠错与输入顺序

2026-11-02 | 专用工作树 intelligent-ui/Piora | 分支 codex/intelligent-ui

1. 本批完成的改动

修正快速输入被旧结果覆盖的问题，并改进形式选择和一次纠错的信息。 相关开发检查通过；真实生成和解释仍有失败，第三阶段尚未完成。

改动	实际行为与边界
普通输入顺序	原生数字框、选择项等携带宿主顺序号；迟到投影不能覆盖未确认的新值，合并输入后按顺序确认
复位边界	复位只确认调用时被取消的旧输入，不提前确认其后刚输入的值；顺序元数据不进入生成程序
三维选择	已确认的选择值未变化时不重复赋值，保留原生下拉框正在进行的键盘选择
回答形式	计算、条件结果、表格和图表优先组件；任务进度、空间操作和超出表达式能力的计算再选小程序，无关键词路由或额外分类模型
有界纠错	语法错误给出行列，完整重提列出所有必填键；版本缺失或已知版本混淆可使用原有一次纠错，不接受未知版本
布局诊断	不支持的 auto-fit/auto-fill 返回可修正的契约错误；九列及以上、尺寸和其他资源超限仍拒绝，不自动删减任务

共用预算仍为 3 次接纳尝试、1 次纠错和首次尝试起 60 秒。没有增加重试次数、扩大运行预算或改写模型的公式。策略更新为 answer-form-2 / mini-app-intent-20；历史程序身份及权限边界保持兼容。

2. 验证结果及失败记录

最新能力检查 **473/473**，共 53 个相关测试文件；14 项能力证据写入后由实际宿主读取确认。来源为 mini-app-capabilities-iddfx2。TypeScript 与本批 lint 通过。不是完整 CI，也不是各平台发布包验收。

- 最初局部检查 67/71：一处提示文字断言与三处未启用隔离开发能力导致的拒绝；恢复原有提示约束，按正式隔离验证入口重跑，原断言保留。
- 首次合并 466/467：组合场景快速切换超时。普通输入增加确认顺序后，精确复现迟到投影的浏览器检查和原场景通过。
- 第二次合并 471/472：对象选择器仍有超时；修正重复赋相同值后，原选择、拾取、镜头恢复检查通过，整组为 472/472。
- 新增复位顺序夹具先稳定失败：复位回包提前确认了新输入 3，本应只确认 2；修正后与真实 Controller 浏览器检查共 6/6，最终纳入 473/473。上述失败日志全部保留。

3. 真实模型生成：固定设置的前后记录

两批均为 8 个开发任务各 3 次。模型配置名 DeepSeek V4.1 Flash，实际请求固定 deepseek-flash、thinking.type=disabled，无 Pro、无 fallback。供应商只返回 deepseek-flash，不能独立确认内部“4.1”身份。该任务集不是泛化白名单，未用于封存验收。

指标	修改前 fqpHyt	修改后 IrmTA2
已安排 / 已完成	24 / 24	24 / 24
有 UI 发布 / 18 个 UI 任务	4 / 18	8 / 18
符合预期形式且完成生成 / 18	2 / 18	8 / 18
首试符合形式且发布 / 18	1 / 18	3 / 18
无 UI 的文字或澄清 / 6	6 / 6	6 / 6
进程或模型失败 / 24	4 / 24	1 / 24

“有发布”不代表形式选对，也不代表公式、过程、文字或恢复正确。失败、超时和漏调用保留在预先安排的分母中，既有指标测试 4/4 通过。两批不是随机对照试验，不能据此声称普遍成功率已提高。

修改后任务族	次数	有发布	预期形式发布	失败
直接回答	3	0	不适用	0
必要澄清	3	0	不适用	0
出行比较	3	1	1	0
优惠计算	3	0	0	0
排序过程	3	2	2	1
几何拖动	3	1	1	0
量水操作	3	2	2	0
井字棋	3	2	2	0

另有 vC5bsi 的 24 次先行记录，其实际 44 次 HTTP 请求开启了思考；与既定设置不一致，已保留并标为不可比较。发现配置问题时该进程已自然完成，关闭尝试没有终止其他进程。修正评估入口后，先验证真实请求确为 disabled，再运行上表两批。首次缺少 thinking 字段的试探在出网前被拒绝；不记为模型通过。

4. 原始生成结果的真实桌面重放

重放 fqpHyt 中两份已发布小程序，原始报告哈希保持不变。运行于独立 Windows Electron 开发桌面，复用桌面测试生命周期。输入、保存、刷新和发送追问全部通过 UI；接口只读取状态核对，凭据仅用于内存中继。发生于复位边界补修前的 472/472 代码快照，不能表述为最新代码的完整原生验收。

样本	操作与数值结果	仍存在的语义问题
排序 sorting-3	12 个检查点；六次比较的数组和五次交换吻合，途中及终局刷新、复位、单步和播放恢复通过	第一步实际比较 6 和 2，说明却写 6 大于 5；追问把六次逻辑推进说成六次点击
量水 jugs-3	9 个检查点；六步得到 (3,4) 升，途中及终局刷新、终态保持通过	追问虽给出 3/3 和 4/5 升，却又称两杯都满，文字不一致

真实追问均收到了最新保存摘要和 tick；实际请求核对为 Flash、关闭思考。排序自动文字检查令整个重放结果为 failed；量水操作项完成，但独立审阅补充追问错误，两份均不能记为完整任务通过。窗口、进程和端口清理无错误。所见截图中的控件、数值可读，未覆盖滚动区域之外及全部外观矩阵。

新增重放入口支持按准确原始报告绑定控件与独立预期，区分运行、计算、文字和追问结果；使用说明见 docs/intelligent-ui-natural-task-replay.md。相关文件保存在 desktop-e2e-brHMKG，包含 task-replay.json、semantic-review.json、截图和生命周期报告。

5. 下一批与尚未完成项

继续处理模型对“上一步、当前状态、下一步”的解释，以及规则和图形的一致性；拓展首批原始结果的操作验证、完整恢复矩阵及开发集。计划仍为 48 个初始任务，32 开发、16 封存，每例 3 次；本批没有完成这一范围。完整 CI、封存集与两人独立人工语义验收按约定在三个阶段开发后执行。没有提交、推送或本地发布包构建。